会学习的红绿灯

——基于纯 Python 手写 Q 学习的自适应交通信号控制

作者：_____　学校：_____　指导教师：_____

2026 年深圳市龙华区人工智能创意编程挑战赛·Python 组

在线演示：`https://zongruichd-rd.github.io/bisai2/`　源代码：`https://github.com/ZONGRUICHD-Rd/bisai2`

摘　要

传统定时红绿灯按固定时间表轮换，不随路况变化，常常出现“一边排长队、另一边空等”的现象。本作品用 Python 标准库从零实现了一个十字路口交通仿真，并手写 Q 学习（Q-learning）算法控制信号灯：AI 把路况抽象为“绿灯方向车数、红灯方向车数、红灯方向最久等待时间”三个分档特征，以“等待车辆的着急程度”的相反数作为奖励，用考虑动作持续时间的半马尔可夫更新、经验回放和自适应学习率进行学习；最短/最长绿灯、黄灯、全红清空和救护车优先等安全约束由独立的规则层保证。在左右两个路口共用同一随机车流的对照实验中，AI 信号灯在早高峰、晚高峰、平峰、深夜和全天五个场景下均优于定时信号灯，平均每车等待时间减少 51%～67%（平均 59.7%）；消融实验表明，经验回放使 6 个随机种子的训练结果全部稳定优于定时灯。作品还将画面抽象为“绘图指令清单”，同一份 Python 代码可在电脑窗口、网页浏览器、手机和视频渲染四种环境中运行。

关键词：强化学习；Q 学习；经验回放；自适应交通信号控制；交通仿真；Python

1　引言

1.1　问题来源

每天上学路上，常能看到这样的情景：一个方向排着长长的车队，另一个方向一辆车都没有，红灯却还要亮满时间。这是因为大多数路口使用**定时控制**：信号周期和绿灯时长按历史流量事先算好 [7]，运行时不随实时车流调整。

龙华区的交通还有明显的“潮汐”特点：很多居民早上向南去福田、南山上班，晚上再返回龙华，早晚高峰的主要车流方向正好相反。一个固定的时间表很难同时照顾好早高峰、晚高峰和深夜。

1.2　研究目标

什么路况该切换、什么时候该保持，很难人工写成完整的规则。强化学习 [1] 不需要人给出“标准答案”，智能体通过“观察—尝试—看结果—总结经验”自己学会决策，非常适合这个问题。本作品的目标是：



图 1: 作品主界面（网页版，早高峰 8 倍速）。左：定时信号灯；右：AI 信号灯；两路口迎来完全相同的车流。右侧面板依次为实时对比、AI 的 Q 表热力图与“AI 心声”、控制台；下方曲线为平均等待时间。

1. 用 Python 搭建可视化的十字路口交通仿真，车辆会跟车、会停车、不会闯红灯；
2. 不借助任何 AI 库，手写 Q 学习算法 [2] 控制信号灯；
3. 让 AI 与定时信号灯在完全相同的车流下公平对比，用数据检验效果；
4. 让评委和同学无需安装软件，在浏览器和手机上即可体验。

2　相关工作

定时与感应控制。Webster 公式 [7] 根据流量计算最优周期，是定时控制的经典方法；SCOOT[8]、SCATS[9] 等系统利用检测器在线调整配时，但依赖人工设计的规则与参数。

强化学习信号控制。Abdulhai 等 [6] 较早将 Q 学习用于单路口信号控制，证明了其自适应能力。DeepMind 用深度 Q 网络（DQN）玩 Atari 游戏时提出的**经验回放** [3, 4] 能显著提高样本利用率和训练稳定性。本作品在表格型 Q 学习中引入经验回放，并通过实验验证了其作用（第 6.3 节）。

3　系统设计

系统按职责分为五层（图 2），上层只依赖下层的接口：交通仿真不知道谁在指挥它，控制器不知道画面怎么画，绘图代码不知道自己画在哪里。这样改动任何一层都不

会影响其他层，也让同一份代码可以运行在四种环境中。

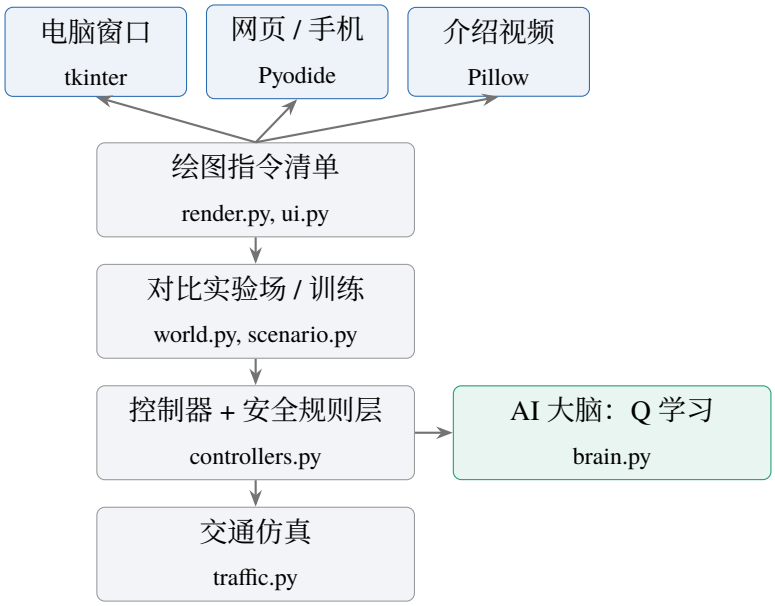


图 2: 系统分层结构。箭头表示“调用 / 依赖”。绘图层只输出与平台无关的指令清单，由三种前端分别绘制。

4　方法

4.1　交通仿真

每条进口车道上的车辆按顺序排列，第 i 辆车只用车头位置 s_i 和速度 v_i 描述。受 Gipps 安全跟车思想 [10] 启发，每一步先求出车辆前方“必须停下的位置”L_i（前车车尾减最小间距 g_0，或红灯时的停止线 s_{stop}），再保留与速度成正比的时间车距 h：

$$d_i = L_i - h\,v_i - s_i, \qquad v_i^{\text{safe}} = \sqrt{2\,b\,\max(d_i, 0)}, \tag{1}$$

$$v_i \leftarrow \begin{cases} \min\!\left(v_i + a\,\Delta t,\ v_i^{\max},\ v_i^{\text{safe}}\right), & v_i^{\text{safe}} > v_i, \\ \min\!\left(v_i^{\max},\ v_i^{\text{safe}}\right), & \text{否则}, \end{cases} \qquad s_i \leftarrow \min\!\left(s_i + v_i\Delta t,\ \max(s_i, L_i)\right). \tag{2}$$

其中 a、b 为加速度和最大减速度。第二式中的截断保证车辆**永不追尾、永不越过红灯停止线**。黄灯时，若剩余距离满足 $s_{\text{stop}} - s_i \geq v_i^2/(2b_c)$（$b_c$ 为舒适减速度）则停车，否则通过，与真实驾驶相同。取 $h = 0.45\,\text{s}$ 时，一条车道的饱和流率约为 1 辆/秒，接近真实路口。

信号灯是一个状态机：绿灯 → 黄灯（2 s）→ 全红清空（1 s）→ 另一方向绿灯。控制器只能“申请切换”，是否允许由信号灯根据最短绿灯（4 s）判断。

4.2　马尔可夫决策过程建模

状态。采用以当前绿灯为参照的**相对视角**：

$$s = \big(\beta_q(n_g),\ \beta_q(n_r),\ \beta_w(w_r)\big), \tag{3}$$

n_g、n_r 分别为绿灯方向和红灯方向尚未通过停止线的车辆数，w_r 为红灯方向等待最久的车辆的等待时间。β_q 把车数分为 $\{0\},\{1,2\},\{3..5\},\{6..9\},\{10+\}$ 五档，β_w 把等待时间分为 <10 s、10～25 s、>25 s 三档，共 $5\times5\times3=75$ 个状态。相对视角使南北向学到的经验可直接用于东西向，状态数减半。

动作。$a\in\{$保持, 切换$\}$，AI 在绿灯亮满 4 s 后每秒决策一次。

奖励。奖励为等待车辆“着急程度”的相反数在动作持续期间的积分：

$$r = -\frac{1}{10}\int_{t_0}^{t_0+\tau}\ \sum_{j\in\mathcal{W}(t)}\Big(1+\frac{w_j(t)}{30}\Big)\,\mathrm{d}t, \tag{4}$$

$\mathcal{W}(t)$ 为此刻正在等待的车辆集合，w_j 为第 j 辆车已等待的秒数。每多等 30 秒着急程度加 1，使 AI 不会为了减少排队总数而让少数车辆一直等待（公平性）。

4.3　半马尔可夫 Q 学习

“保持”只持续 1 s，而“切换”要经过黄灯与全红，下一次决策至少在 7 s 之后，两个动作持续时间不同。因此采用半马尔可夫决策过程的更新形式 [5]，用动作实际持续的秒数 τ 计算折扣：

$$Q(s,a)\leftarrow Q(s,a)+\alpha_n\Big[\,r+\gamma^{\tau}\max_{a'}Q(s',a')-Q(s,a)\Big], \tag{5}$$

其中 $\gamma=0.95$（每秒）。这样切换带来的约 3 秒“谁都不能走”的损失会真实地进入回报，AI 自己学会“不要乱切换”。

自适应学习率。第 n 次遇到某状态时取 $\alpha_n=\max(0.1,\,1/n)$：初次遇到的路况完全采信新经验（学得快），见多后稳定在 0.1（不被偶然事件带偏）。

探索。采用 ε-贪心策略，$\varepsilon=\max\big(\varepsilon_{\min},\,0.3\,e^{-N/400}\big)$，$N$ 为累计学习次数：新大脑多探索，经验越多越自信。展示时 $\varepsilon_{\min}=0.02$。

经验回放。每条经验 (s,a,r,s',τ) 存入容量 5000 的回忆库（满后随机替换），每学习一条新经验，再随机抽取 $K=20$ 条旧经验按式 (5) 复习一遍，完整流程见算法 1。

4.4　安全规则层

安全相关的约束不交给 AI “试错”，而由规则层强制执行：

- 最短绿灯 4 s、黄灯 2 s、全红 1 s：写在信号灯状态机中，AI 只能申请，无法违反；
- 最长绿灯 40 s：另一方向有车时必须轮换，保证不会有车辆被无限期“饿死”；
- 救护车优先：检测到红灯方向有救护车时立即切换，为生命通道让路。

即“AI 负责优化，规则负责兜底”，这也是在现实中使用人工智能应有的方式。

算法 1 带经验回放的半马尔可夫 Q 学习控制器（每个仿真步调用）

输入： 路口快照；Q 表；回忆库 $\mathcal{M}$；上一次决策 $(s_{\text{prev}}, a_{\text{prev}})$

累积奖励 $R \leftarrow R - \frac{1}{10}\sum_{j\in\mathcal{W}}(1 + w_j/30)\,\Delta t$，计时 $\tau \leftarrow \tau + \Delta t$
if 红灯方向有救护车 **且**绿灯方向没有 **then** ▷ 安全规则层
    立即申请切换；丢弃本次经验；**return**
end if
if 非绿灯阶段 **或**绿灯 < 4 s **或**距上次决策 < 1 s **then return**
end if
观察状态 s
if s_{prev} 存在 **then**
    按式 (5) 用 $(s_{\text{prev}}, a_{\text{prev}}, R, s, \tau)$ 更新，学习率 α_n
    把该经验存入 $\mathcal{M}$；从 $\mathcal{M}$ 随机取 K 条按式 (5) 再学一遍（学习率 α）
end if
if 绿灯已亮 ≥ 40 s **且**红灯方向有车 **then** $a \leftarrow$ 切换 ▷ 最长绿灯规则
else $a \leftarrow \varepsilon$-贪心 $(Q(s, \cdot))$
end if
if $a =$ 切换 **then** 申请切换
end if
$(s_{\text{prev}}, a_{\text{prev}}) \leftarrow (s, a)$；$R \leftarrow 0$；$\tau \leftarrow 0$

4.5 可解释性

为让人看懂 AI 的想法，界面实时显示 Q 表热力图：格子颜色表示 $Q(s, \text{切换}) - Q(s, \text{保持})$ 的正负与大小，白框标出当前路况；“AI 心声”把每一次决定翻译为自然语言，如“东西向有 6 辆车在等，南北向只剩 1 辆 → 切换”。

5 实现

5.1 一套代码，四种运行环境

绘图代码不直接调用任何图形库，而是输出一份与平台无关的**绘图指令清单**，例如 `["r", x, y, w, h, fill, ...]` 表示一个矩形。四种前端各自把清单画出来：电脑版用 tkinter；网页版通过 Pyodide 在浏览器中运行**同一份** Python 代码，再用 HTML canvas 绘制；手机版在网页版基础上实现了全屏与竖屏自动旋转；介绍视频则用 Pillow 逐帧绘制。作品本身只依赖 Python 标准库，可在海龟编辑器中直接运行。

5.2　核心代码

Q 学习的更新只需几行（`smartlight/brain.py`）：

```
def _update(self, state, action, reward, next_state, duration, rate):
    v = self.values(state)
    target = reward + (self.gamma ** duration) * max(self.values(next_state))
    td_error = target - v[action]
    v[action] += rate * td_error
    return td_error
```

5.3　参数

所有可调参数集中在 `config.py` 中，主要取值见表 1。

表 1: 主要参数

参数	取值	参数	取值
仿真步长 Δt	1/30 s（训练 0.1 s）	学习率 α	0.1
时间车距 h	0.45 s	折扣 γ（每秒）	0.95
最短 / 最长绿灯	4 s / 40 s	回放容量 / 每次复习 K	5000 / 20
黄灯 / 全红	2 s / 1 s	展示探索率 $\varepsilon_{\min}$	0.02
定时灯绿灯	15 s（周期 36 s）	预训练	24 小时虚拟车流

6　实验

6.1　实验设置

公平对照。两个路口共用同一个随机来车源：每辆车在同一时刻、从同一方向、以同样的最高速度到达两个路口（控制变量法），差别仅在信号控制器。车辆到达服从泊松过程，各方向强度随时刻变化：早高峰（8:00）北向南最大 0.55 辆/秒，晚高峰（18:20）南向北最大 0.53 辆/秒，深夜约 0.03 辆/秒，模拟龙华的潮汐车流。

评价指标。平均等待时间定义为

$$\bar{W} = \frac{\text{所有车辆停车等待的总秒数（含仍在排队的车）}}{\text{到达车辆数}}. \tag{6}$$

制作过程中曾只统计“已驶离路口的车辆”，结果 AI 看上去成绩很好；后来发现一直被堵住、开不走的车根本没被计入，当时的 AI 实际上会让一个方向长期“饿死”。改用上式后问题才暴露出来。**选对评价指标与写对算法同样重要**。此外按怠速 1 s 排放 0.39 g CO_2 估算排放。

所有实验可用 `python tools/experiments.py` 复现。

6.2　主要结果

表 2 与图 3 给出预训练 AI（训练 24 小时虚拟车流，学习 22 643 次）与定时灯在 5 个场景下各运行 1200 s 的结果（测试时关闭探索与学习）。AI 在全部场景中获胜，平均等待时间减少 51.0%～67.3%，平均 59.7%；通过车辆数不减反增，早高峰 20 分钟少排放约 3.2 kg CO_2。

表 2: 定时信号灯与 AI 信号灯对比（1200 s 仿真，随机种子 11）

场景	平均等待（s/辆）		减少	通过车辆	少排放 CO_2（g）
	定时	AI		定时 / AI	
早高峰	10.49	**4.15**	60.4%	1237 / 1257	3150
晚高峰	9.64	**3.58**	62.9%	1195 / 1210	2884
深夜	6.21	**2.03**	67.3%	130 / 131	215
智能一天	5.56	**2.39**	57.0%	582 / 583	719
平峰	4.65	**2.28**	51.0%	516 / 517	485

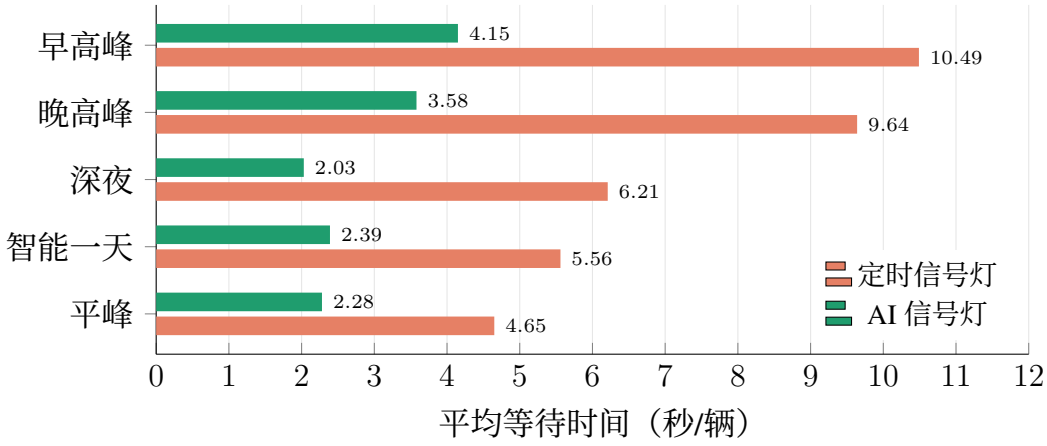


图 3: 五个场景下的平均等待时间。差距在早晚高峰最大（定时灯给两个方向相同绿灯，车多的方向越排越长）；深夜相对减少最多（AI “有车就放行”）。

6.3　消融实验：经验回放

在不使用经验回放（$K = 0$）时我们发现，同样的代码换一个随机种子，训练结果差异很大。为此用 6 个随机种子各训练 2 小时虚拟车流，比较 $K = 0$ 与 $K = 20$，每个大脑在 4 个时刻各测试 900 s（表 3）。

不回放时，6 个种子中有 3 个在至少一个场景比定时灯更差，最差的早高峰平均等待达 63.1 s；使用经验回放后，24 个测试结果**全部**优于定时灯，且不同种子之间非常接近（早高峰 4.0～5.2 s）。经验回放让同样多的经历被反复利用，把稀有但关键的路况（如严重拥堵）记得更牢。

表 3: 经验回放消融（平均等待，s/辆；**红色粗体**表示比定时灯更差）

	不回放（$K=0$）				经验回放（$K=20$）			
种子	早高峰	平峰	晚高峰	深夜	早高峰	平峰	晚高峰	深夜
1	5.9	2.8	5.0	2.7	4.3	2.5	3.1	2.8
2	**26.7**	2.9	14.7	1.3	5.2	2.3	4.7	2.4
3	**63.1**	**7.6**	**26.5**	1.3	5.0	2.4	3.3	2.7
4	7.6	3.0	6.9	**8.4**	4.9	2.4	3.7	1.3
5	4.4	2.5	4.9	2.8	4.8	2.6	4.8	1.3
6	11.0	2.5	9.5	1.3	4.0	2.6	3.5	1.3
平均	19.8	3.6	11.3	3.0	**4.7**	**2.5**	**3.9**	**2.0**
定时灯	21.5	4.8	18.7	4.7	21.5	4.8	18.7	4.7

6.4　从零学习的过程

图 4 记录了清空大脑后在早高峰边用边学的过程。前 3 分钟 AI 还在摸索，表现不如定时灯；第 4 分钟起反超，第 10 分钟时 AI 平均等待 7.2 s，而定时灯已升至 39.2 s。图 5 对比了学习前后的 Q 表。

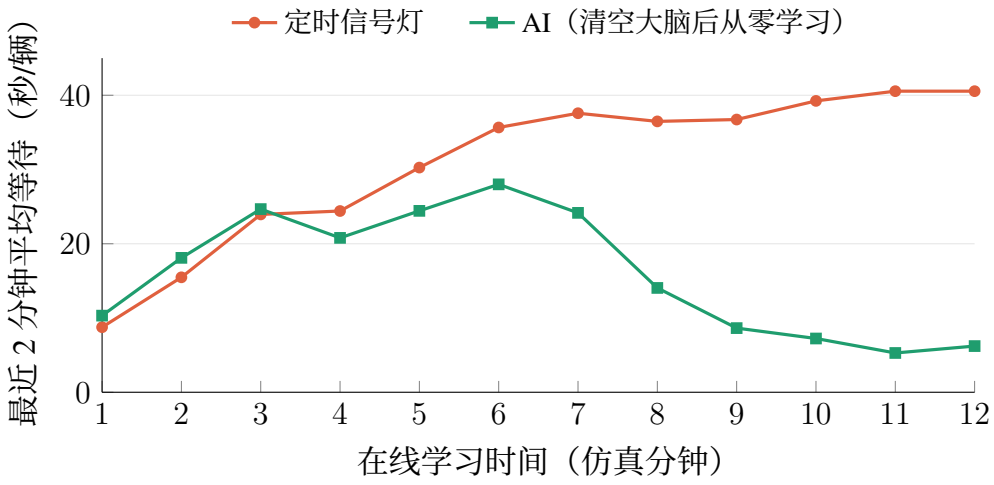


图 4: 早高峰中从零开始的在线学习曲线（`World` 种子 9，大脑种子 3）。12 分钟内 AI 共学习 305 次。

6.5　测试

项目包含 9 个自动测试（`python -m unittest`）：车辆不追尾、不闯红灯；AI 完全随机决策时安全时间仍被遵守；Q 学习公式数值正确；回忆库容量受限；预训练 AI 在 3 个时刻均比定时灯好 20% 以上；救护车优先；界面能正常生成绘图指令。每次推送代码后，GitHub Actions 自动运行测试并发布网页。



(a) 清空大脑后：Q 表全是“?”



(b) “极速训练”2 小时后：长出规律

图 5: Q 表的变化（右侧面板中部）。橙色 = 该切换，蓝色 = 该保持：红灯方向车多、绿灯方向车少时切换，反之保持。

7　讨论与反思

收获。AI 并不神秘，它的“聪明”来自三件事：看什么（状态）、追求什么（奖励）、怎样总结经验（学习算法）。奖励设计不当时 AI 会“钻空子”，例如只看排队总数时，它会让少数车辆永远等下去。

不足与改进方向。

1. 只模拟直行车流，可加入左转、行人过街和更多相位；
2. 只控制单个路口，可让多个路口的 AI 协同，形成“绿波带”；
3. 表格型 Q 学习只能处理分档后的路况，可尝试深度强化学习 [4] 处理更细致的状态；
4. 车流为模拟数据，若接入真实交通流量数据，结论将更接近实际应用。

AI 伦理。用 AI 管理公共交通时，效率不是唯一目标，还必须兼顾公平（不让少数人一直等）、安全（规则兜底）与特殊需要（救护车优先）。

作者反思。（请作者在此用自己的话补充制作过程中的经历与体会。）

8　结论

本作品用纯 Python 标准库实现了交通仿真与 Q 学习信号控制，并通过公平对照实验证明：AI 信号灯在五个典型场景中平均减少 59.7% 的等待时间，经验回放显著提高了学习的稳定性，安全规则层保证了 AI 的决策始终在安全范围之内。作品支持电脑、网页与手机运行，评委可在线直接体验。

参考文献

[1] R. S. Sutton, A. G. Barto. *Reinforcement Learning: An Introduction* (2nd ed.). MIT Press, 2018.

[2] C. J. C. H. Watkins, P. Dayan. Q-learning. *Machine Learning*, 8: 279–292, 1992.

[3] L.-J. Lin. Self-improving reactive agents based on reinforcement learning, planning and teaching. *Machine Learning*, 8: 293–321, 1992.

[4] V. Mnih, K. Kavukcuoglu, D. Silver, et al. Human-level control through deep reinforcement learning. *Nature*, 518: 529–533, 2015.

[5] S. J. Bradtke, M. O. Duff. Reinforcement learning methods for continuous-time Markov decision problems. In *Advances in Neural Information Processing Systems 7*, 1995.

[6] B. Abdulhai, R. Pringle, G. J. Karakoulas. Reinforcement learning for true adaptive traffic signal control. *Journal of Transportation Engineering*, 129(3): 278–285, 2003.

[7] F. V. Webster. *Traffic Signal Settings*. Road Research Technical Paper No. 39, HMSO, London, 1958.

[8] P. B. Hunt, D. I. Robertson, R. D. Bretherton, R. I. Winton. SCOOT—a traffic responsive method of coordinating signals. TRRL Laboratory Report 1014, 1981.

[9] A. G. Sims, K. W. Dobinson. The Sydney coordinated adaptive traffic (SCAT) system philosophy and benefits. *IEEE Transactions on Vehicular Technology*, 29(2): 130–137, 1980.

[10] P. G. Gipps. A behavioural car-following model for computer simulation. *Transportation Research Part B*, 15(2): 105–111, 1981.

A　运行方法

- **电脑：**用海龟编辑器或 IDLE 打开 `main.py` 直接运行（保持 `smartlight` 文件夹在同一目录，无需安装任何库）。
- **网页 / 手机：**打开 `https://zongruichd-rd.github.io/bisai2/`，手机上点击“全屏演示”。
- **命令行：**`python train.py`（训练并考试）、`python -m unittest`（自动测试）、`python tools/experiments.py`（复现本文全部实验）。

B　评分标准对照

评分项	本作品的对应
思想性、规范性	用人工智能解决身边的交通拥堵与碳排放问题，关注公平与生命通道；论文、README 齐全，源码均有中文注释
功能与人机交互	一键运行；按钮、快捷键、触屏三种操作；开场引导与原理说明；网页与手机在线体验
创新性	公平对照实验；Q 表可视化与“AI 心声”；“AI 做梦”极速训练；一套代码四种运行环境
艺术性	夜景城市俯视风格；刹车灯、救护车警灯、久等车辆“生气”提示等细节
技术性	分层架构；手写半马尔可夫 Q 学习、经验回放、自适应学习率；9 个自动测试；实验可复现